

[분석 보고서]

부문		☐ 자유분석 ☒ 지정분석
팀 명		BK3
과제명		공공기관 사회적 책임 구매 목표 달성을 위한 환경시설 관급자재 공급망 분석 모델 개발
미션		☐ 자연환경 ☐ 생활환경 ☐ 대기환경 ☐ 물환경 ☒ 환경일반 ☐ 에너지산업 ☐ 에너지효율 ☐ 미래에너지 ☐ 에너지환경
활용 데이터	공공	조달청 나라장터 낙찰정보서비스, 조달청 나라장터 사용자정보서비스, 조달청 조달업체공급물품정보조회, 조달청 부정당제재업체정보조회, 주식회사 한국중소벤처기업유동원 공공구매종합정보망 인증서 정보 제공 서비스, 한국장애인고용공단 장애인 표준사업장 실시간 조회, 창업진흥원 창업기업확인서 발급기업정보 조회서비스, 국가보훈부 자활용사촌 복지공장 생산품목, 한국사회적기업진흥원 사회적기업 관련 공개자료, 협동조합 사회적협동조합 관련 공개자료
	민간	해당 없음

I. 과제 개요 및 가설
공공기관은 사고, 재난, 긴급 고장 등의 긴급한 상황에서도 시설이 안정적으로 운영될 수 있도록 필요한 자재를 확보해야 하며, 특히 한국환경공단과 같이 환경시설 관리 및 운영과 밀접한 기관일 경우에는 긴급 자재 공급 지연은 환경 서비스 중단, 시설 복구 지연, 행정비용 증가 등으로 이어질 수 있다. 그러므로 환경시설 긴급 자재에 대해 어떤 업체가 실제로 공급할 수 있는지, 낙찰 이력이 있는지, 공급 안정성과 신뢰성을 확보했는지를 사전에 파악하는 것은 매우 중요하다.
또한 공공기관은 긴급 자재들을 신속하게 확보하는 것을 넘어, 사회적 책임 구매 목표를 달성해야 함도 매우 중요하다. 즉 가격이나 낙찰 가능성을 기준으로 업체를 선정하는 것이 아니라 사회적 기업, 사회적 협동조합, 자활용사촌복지공장 등 사회적 가치가 있는 업체를 발굴 및 추천하는 과정이 반영될 필요가 있다. 그러나 현재 공개된 데이터는 낙찰정보, 조달업체공급물품정보, 사회적 가치 인증 정보 등 다양하게 분리되어 있어 긴급 자재별 적합 공급업체를 종합적으로 판단하기에는 제한되는 부분이 많다
본 과제를 통하여 나라장터 낙찰정보와 조달업체공급물품정보등 여러 가지 데이터를 연계하여 환경시설 긴급자재별 공급 가능 업체를 확인하고 사회적 가치를 고려하여 공공기관의 사회적 책임 구매 목표를 달성하는 공급망 분석모델을 개발하는 것을 주요한 목표로 한다.
II. 분석 환경 및 데이터
1. 분석 환경 해당 분석은 Python 환경에서 수행하였으며(Python 3.14 버전), 데이터 처리와 모델링 재현성을 확보하기 위해 numpy, pandas, scikit-learn, joblib, requests 등의 라이브러리를 활용하였다. 보다 자세한 라이브러리 목록은 아래와 같다.

joblib	1.5.3
numpy	2.4.4
openpyxl	3.1.5
pandas	3.0.2
python-dateutil	2.9.0.post0
requests	2.33.1
scikit-learn	1.8.0
scipy	1.17.1
six	1.17.0
threadpoolctl	3.6.0
tzdata	2026.2
urllib3	2.6.3

원천 데이터 수집, 전처리, 후보 업체 생성, feature 병합, 모델 학습 및 대시보드 생성 등 전 과정에서는 필요한 부분들을 각각 Python 코드로 분리하여 관리하고 사용함으로써 작업 흐름을 체계적으로 구성할 수 있도록 하였다. 또한 API 인증키는 코드에 직접 저장하지 않고 환경변수 방식으로 관리하여 보안성과 재현성을 함께 고려하였다.

2. 데이터 전처리

공개된 조달청 나라장터 낙찰정보서비스, 나라장터 사용자정보서비스, 공공구매종합정보망 인증서 정보, 장애인 표준사업장, 창업기업, 자활용사촌 복지공장, 사회적기업, 사회적협동조합 등 다양한 공개 데이터들을 바탕으로 raw 데이터들을 얻었다. 자세한 목록은 아래와 같다.

포털명	URL
나라장터 낙찰정보서비스	https://www.data.go.kr/data/15129397/openapi.do#tab_layer_prcuse_exam
나라장터 사용자정보서비스	https://www.data.go.kr/data/15129466/openapi.do
주식회사한국중소벤처기업유동원 공공구매종합정보망 인증서 정보 제공 서비스	https://www.data.go.kr/data/15062581/openapi.do?recommendDataYn=Y
한국장애인고용공단 장애인 표준사업장 실시간 조회	https://www.data.go.kr/data/15119304/openapi.do
창업진흥원 창업기업확인서발급기업정보 조회서비스	https://www.data.go.kr/data/15125362/openapi.do
국가보훈부 자활용사촌 복지공장 생산품목	https://www.data.go.kr/data/15131425/fileData.do
사회적기업포털	https://www.seis.or.kr/mainPage.do
협동조합	https://www.coop.go.kr/home/index.do
한국사회적기업진흥원	https://www.socialenterprise.or.kr/

이후 수집한 원천 데이터들은 서로 다른 인코딩과 형식을 가진 CSV 파일 및 API 응답으로 출력되었다. 이를 일관되게 읽을 수 있도록 정리하고, 사업자등록번호는 하이픈과 특수문자를 제거하여 정규화하였다. 날짜 정보는 등록일시와 개설 일자를 기준으로 통일하였으며, Y/N 여부 값과 숫자형 값, 비어 있는 값은 분석이 가능한 형태로 변환하였다. 이때 확실하지 않은 값은 임의로 보정하지 않고, 빈칸이나 보수적인 값으로 처리하여 데이터 왜곡을 최소화할 수 있도록 하였다. 또한 bidNtceNo, dminsttNm등과 같이 영어로 되어 있는 원천 컬럼명을 입찰공고번호, 수요기관명과 같이 분석용 한국어 표준 컬럼명으로 변환하여 표준 데이터셋으로 재구성하였다. 아래에는 csv raw 데이터 파일들의 원천 컬럼명을 한국어 표준 컬럼명으로 변환하는 코드의 일부분을 첨부하였다(나라장터 사용자정보서비스, 조달업체기본정보조회).

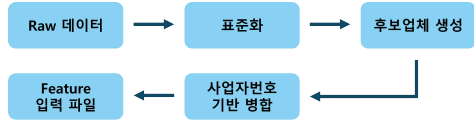
```

user_base = RAW / "나라장터_사용자정보서비스"
basic = read_many_csvs((user_base / "2. 조달업체기본정보조회").glob("*.csv"))
basic_mapping = [
    ("사업자번호", ("bizno",)),
    ("업체명", ("corpNm",)),
    ("영문업체명", ("engCorpNm",)),
    ("개업일자", ("opbizDt",)),
    ("지역코드", ("rgnCd",)),
    ("지역명", ("rgnNm",)),
    ("우편번호", ("zip",)),
    ("주소", ("adrs",)),
    ("상세주소", ("dtlAdrs",)),
    ("전화번호", ("telNo",)),
    ("팩스번호", ("faxNo",)),

```

3. 데이터 융합

전체적인 과정을 보면 공공 데이터와 민간·외부 데이터의 결합은 사업자등록번호를 정규화한 값인 10자리 수의 '사업자번호_정규화'를 핵심 키로 하여 진행하였다. 물품-업체 조합 단위의 데이터는 세부품명번호+사업자번호 또는 조합별로 붙여지는 숫자인 candidate_id를 기준으로 병합하여 관리하였다. 이를 통해 후보 업체별 간의 특성을 일관되게 연결할 수 있도록 하였다. 조달업체 기본정보를 통해서는 업체명과 주소 등 기본 식별 정보를 보강하고, 낙찰정보를 통해서는 낙찰건수, 낙찰금액, 최근낙찰일 등의 실적 정보를 결합하였다. 이와 함께 부정당재제, 창업기업, 장애인표준사업장, 공공구매인증, 사회적기업, 사회적협동조합, 자활용사춘 복지공장 등의 정책 및 사회적 가치 데이터도 함께 통합하여 후보 업체의 특성을 확장할 수 있도록 하였다. 만약 업체의 이름이 서로 유사하더라도 사업자등록번호가 일치하지 않으면 확정 매칭으로 보지 않는 보수적 기준을 적용하였으며, 사업자번호가 없는 일부 데이터는 업체명 정규화를 통한 보조 매칭만 수행하여 정합성을 유지하려고 하였다. 최종적으로는 후보 업체 목록과 feature 입력 파일을 구성해 이후 모델링 단계에서 활용할 수 있도록 통합 데이터를 완성하였다.



후보 업체 선정 과정에서는 조달업체 공급물품정보조회 데이터를 기준으로 품목별 공급 가능 업체를 먼저 선별한 뒤, 해당 품목과의 연관성이 높은 업체를 우선적으로 구성하였다. 이때 공급물품이 실제로 등록된 업체만 후보군에 포함하는 것을 원칙으로 하였으며, 공급물품_일치는 점수화 대상이 아니라 후보 선정의 필수 조건으로 설정하였다. 낙찰정보만으로는 어떤 업체가 실제로 낙찰되었는지는 확인할 수 있지만, 해당 업체가 어떤 물품을 공급 가능 품목으로 등록했는지는 확인하기 어렵다. 따라서 조달업체공급물품정보와 교차 검증하여 실제 낙찰 이력과 공급 가능 품목을 함께 확인하였다. 이를 통해 단순 낙찰 실적뿐 아니라 물품별 공급 가능성까지 고려한 후보 업체 구성이 가능하도록 하였다. 이후 2022~2025년 낙찰정보에서 낙찰 건수와 낙찰금액이 높은 업체를 우선순위로 반영하여 품목별 후보업체를 선정하였고, 최종적으로 품목별 50개씩 후보업체 목록을 구성하였다. 업체들의 실제 조달 이력과 공급 가능성을 함께 고려하여 후보업체를 선정하고자 하였다. 아래는 후보 업체를 선정하는 코드의 일부이다.

```

def select_candidates(top_per_item: int, start_year: int, end_year: int) -> tuple[list[dict[str,
supply_by_item = load_supply_by_item(start_year, end_year)
basic_names = load_basic_names()
award_stats = load_award_stats(start_year, end_year)

rows: list[dict[str, str]] = []
summary: list[dict[str, Any]] = []

candidate_id = 1
for item_code, item_name in DEFAULT_ITEMS:
    item_supply = supply_by_item.get((item_code, item_name), {})
    suppliers = sorted(item_supply)
    ranked = sorted(
        suppliers,
        key=lambda bizno: (
            -award_stats[bizno]["count"],
            -award_stats[bizno]["amount"],

```

이어서 공공 데이터와 외부 데이터를 결합하는 과정에서는 사업자등록번호 정규화 값을 핵심 식별자로 사용하여 정합성을 확보하였다. 업체명은 보조 정보로 활용되되, 이름이 유사하더라도 사업자등록번호가 일치하지 않으면 확정 매칭으로 보지 않는 보수적 기준을 적용하였다. 또한 사업자등록번호가 없는 일부 데이터는 업체명 정규화를 통해 보조적으로만 연결하였으며, 확실히 해당하지 않는 값은 임의로 채우지 않고 빈칸으로 두거나 별도 비교로 남겨 데이터 왜곡을 최소화하였다. 이와 같은 방식으로 데이터 결합의 정확도를 높이고, 이후 분석에 사용할 수 있는 일관된 후보 업체 목록과 feature 입력 파일을 구성하였다. 아래는 feature 입력을 병합하는 코드의 일부이다.

```

def merge_features(candidates: list[dict[str, Any]], feature_paths: list[Path]) -> tuple[list[di
by_candidate_id = {candidate_id_from_row(row): row for row in candidates if candidate_id_fro
by_item_bizno: dict[tuple[str, str], list[dict[str, Any]]] = defaultdict(list)
by_bizno: dict[str, list[dict[str, Any]]] = defaultdict(list)
for row in candidates:
    bizno = normalized_bizno_from_row(row)
    item_code = item_code_from_row(row)
    if item_code and bizno:
        by_item_bizno[(item_code, bizno)].append(row)

```

최종적으로는 이와 같은 전처리와 정합성 검증을 통해 분석용 표준 데이터셋을 구성하고, 세부품명번호와 사업자등록번호를 기준으로 후보업체 목록과 수집하려는 feature들에 따른 여러 데이터 파일을 정리 및 생성하였다. 이를 바탕으로 이후 AI모델 학습 단계에서 해당 분석용 데이터셋들을 사용할 수 있도록 하였다.

III. 분석 방법 및 모델링

1. AI모델

가. 분석 환경 및 데이터

1) 분석 환경

데이터 분석을 위해 Python을 사용하였다(Python 3.14 버전). 또한, 원활한 분석을 진행하기 위해 아래와 같은 라이브러리들을 사용하였다.

joblib	1.5.3
numpy	2.4.4
openpyxl	3.1.5
pandas	3.0.2
python-dateutil	2.9.0.post0
requests	2.33.1
scikit-learn	1.8.0
scipy	1.17.1
six	1.17.0

threadpoolctl	3.6.0
tzdata	2026.2
urllib3	2.6.3

2) 데이터 전처리

공개되어있는 아래의 포털들에서 raw데이터를 얻었다.

포털명	URL
나라장터 낙찰정보서비스	https://www.data.go.kr/data/15129397/openapi.do#tab_layer_prcuse_exam
나라장터 사용자정보서비스	https://www.data.go.kr/data/15129466/openapi.do
주식회사한국중소벤처기업유통원 공공구매종합정보망 인증서 정보 제공 서비스	https://www.data.go.kr/data/15062581/openapi.do?recommendDataYn=Y
한국장애인고용공단 장애인 표준사업장 실시간 조회	https://www.data.go.kr/data/15119304/openapi.do
창업진흥원 창업기업확인서발급기업정보 조회서비스	https://www.data.go.kr/data/15125362/openapi.do
국가보훈부 자활용사촌 복지공장 생산품목	https://www.data.go.kr/data/15131425/fileData.do
사회적기업포털	https://www.seis.or.kr/mainPage.do
협동조합	https://www.coop.go.kr/home/index.do
한국사회적기업진흥원	https://www.socialenterprise.or.kr/

3) 데이터 융합

나. 분석 방법 및 모델링

1) 방법론 타당성

데이터들을 분석하기 위해서 규칙기반 평가와 AI모델의 학습을 통한 평가 두 종류를 진행하였다.

AI모델 분석은 RandomForest, ExtraTrees, HistGradientBoosting의 3가지 모델을 사용하였다. 셋 모두 트리 기반의 앙상블 모델로, 결정트리 여러 개를 모아 더 안정적이고 강한 예측을 만드는 모델을 의미한다. 이때 결정 트리란 질문을 하나씩 던지면서 답을 찾는 나무 형태의 규칙(스무고개 또는 if-else 형식의 질문들)을 뜻한다. 트리를 한 개만 쓰면 특정 데이터에 과도하게 맞춰질 수 있으므로, 결정 트리 여러 개를 잘 활용하여 안정적으로 만든 것이 바로 앙상블 모델이다. 또한, 여러 트리를 합치면 더 안정적인 예측/적은 과적합/개선된 성능의 장점이 있다.

각 모델의 특징은 다음과 같다.

모델명	특징
RandomForest	-안정적이고 무난한 기준선으로, 여러 결정트리를 독립적으로 많이 만들어 평균값을 얻는다. 안정성 및 해석용이성의 장점이 있다. -각 트리가 서로 다른 샘플과 특성 조합으로 학습된다. -전체적으로 안정적인 결과를 도출하며, 데이터 변동이 조금 있어도 성능 변동이 적다.

	-무난한 첫 모델로 적합하다. -RandomForest보다 더 무작위적으로 트리를 만들어 평균값을 얻는다. 보다 빠르고 과적합을 줄이기 쉽다. -RandomForest와 비슷하긴 하지만 분할 기준을 더 랜덤하게 선택한다. -학습 속도가 빠르고 트리들 간 다양성이 더 커질 수 있다.(트리 하나로는 분산이 커질 수 있으나 전체적으로 보면 서로 틀린 부분을 상쇄해 주므로, 전체적인 수준에서는 분산이 줄어들어 과적합이 감소된다.) -그러나 너무 랜덤해서 RandomForest보다 성능이 떨어질 수도 있다는 단점이 있다.
ExtraTrees	-히스토그램을 기반으로 한다. (데이터를 하나하나 분석하지 않고, 막대그래프처럼 데이터를 구간화해서(묶어서) 처리한다.) -트리를 하나씩 순차적으로 추가하며 점진적으로 약점 및 틀린 부분을 보완하는 고성능 모델이다. -이전 모델들의 실수를 다음 모델이 계속 보완하는 방식이다. -예측력은 가장 강한 편이지만 파라미터가 미치는 영향이 크다.(세팅값을 어떻게 잡느냐에 따라 성능이 달라질 수 있다.) -대용량 데이터에서 강함 -RandomForest보다 더 정교한 패턴을 설정하는 스타일
HistGradientBoosting	

2) 분석 프로세스

AI모델을 통한 분석은 연도별 데이터를 여러 조건으로 나누어 테스트하였다. 우선적으로 2022년부터 2025년까지의 데이터를 수집하여 2022~2024년은 train, 2025년은 test로 나누어 각 모델들의 학습을 진행하였다. 이후로 아래와 같이 추가적인 AI모델의 학습 및 평가 과정을 진행하여 각 모델의 성능 확인에 필요한 데이터값들을 얻을 수 있도록 하였다.

가) 2020~2021년의 데이터를 추가하여 학습 및 평가(train 2020~2023, validation 2024, test 2025)

나) 2026년의 데이터를 추가하여 최신성 검증(train 2020~2023, validation 2024, test 2025, latest 2026)

다) train 연도 구간을 통합하여 학습 및 평가, 최종 재학습 시나리오(train 2020~2024, test 2025)

2020~2021년 데이터를 추가함으로써 분석 가능한 데이터의 기간과 표본 수를 확대한다. 이를 통해 모델이 더 다양한 조달 사례를 학습할 수 있으며, 특정 연도에 치우치지 않는 일반화 성능 향상을 기대할 수 있다. 반면 2026년 데이터는 최신 데이터이므로 공식 학습/평가 데이터셋에 섞지 않고 별도로 관리하였다. 이를 통해 학습 데이터와 검증 데이터가 섞이는 데이터 누수를 방지하고, 모델 성능이 과대평가되는 문제를 줄일 수 있다. 또한, 2026년 데이터는 과거 데이터로 학습한 모델이 최신 조달 환경에서도 잘 작동하는지 확인하기 위한 최신성 검증용 테스트베드로 활용되었다.

3) 분석 결과

RandomForest, ExtraTrees, HistGradientBoosting의 3가지 AI 모델들을 통해 성능 평가에 필요한 Hit값과 MRR값을 얻었다. 우선 Hit값은 뒤에 붙는 숫자에 따라 AI모델을 돌렸을 경우 실제 낙찰업체가 해당 등수 안에 나온 비율이 얼마나 되는지를 측정한 값이다. 예를 들어, 100번의 입찰 중 50번에서 실제 낙찰업체를 1등으로 맞다면 Hit@1 = 0.50이다. MRR은 Mean Reciprocal Rank의 약자로, 실제 낙찰업체의 순위에 점수를 매겨 평균낸 값(=실제 낙찰업체 순위의 역수 평균)이다. MRR은 1등에 가까울수록 큰 값을 가진다. 예를 들어, 1등이면 1/1 = 1.0, 2등이면 1/2 = 0.5가 되는 식이다. 아래는 2. 분석 프로세스에서 언급한 연도 구간 조건

별 분석 결과값이다.			
가) 우선적으로 2022년부터 2025년까지의 데이터를 수집하여 학습 및 평가 (train 2022~2024, test 2025)			
	RandomForest	ExtraTrees	HistGradientBoosting
Hit@1	0.504975	0.502488	0.522388
Hit@3	0.717662	0.702736	0.705224
Hit@5	0.814677	0.789801	0.789801
MRR	0.641693	0.631463	0.645592
나) 2020~2021년의 데이터를 추가하여 학습 및 평가(train 2020~2023, validation 2024, test 2025)			
	RandomForest	ExtraTrees	HistGradientBoosting
Hit@1	0.553509	0.526316	0.564035
Hit@3	0.771053	0.742982	0.774561
Hit@5	0.850877	0.821053	0.848246
MRR	0.684313	0.660295	0.692213
다) 2026년의 데이터를 추가하여 최신성 검증(train 2020~2023, validation 2024, test 2025, latest 2026)			
	RandomForest	ExtraTrees	HistGradientBoosting
Hit@1	0.553509	0.526316	0.564035
Hit@3	0.771053	0.742982	0.774561
Hit@5	0.850877	0.821053	0.848246
MRR	0.684313	0.660295	0.692213
latest Hit@1	0.550725	0.546584	0.530021
latest Hit@3	0.792961	0.797101	0.774327
latest Hit@5	0.879917	0.848861	0.859213
latest MRR	0.691544	0.683824	0.672014
라) train 연도 구간을 통합하여 학습 및 평가, 최종 재학습 시나리오(train 2020~2024, test 2025)			
	RandomForest	ExtraTrees	HistGradientBoosting
Hit@1	0.572807	0.546491	0.586842
Hit@3	0.764912	0.734211	0.775439
Hit@5	0.837719	0.817544	0.851754
MRR	0.692252	0.667545	0.703997
이 결과들을 분석하여 2), 데이터 추가 시 Hit값과 MRR값이 세 모델에서 모두 증가하는 것을 확인하였다. 그리고 3), 최신성 검증 시 비슷한 값을 가지는 항목, 값이 줄어든 항목, 값이 늘어난 항목 등 전체적으로 일관성은 보이지 않으나 ExtraTrees의 latest Hit@3, HistGradientBoosting의 latest Hit@1 제외 0.03 이상의 큰 변동은 보이지 않은 것을 확인하였다. 또한 4), 연도구간 통합 최종 재학습 시나리오에서는 2)와 비교하여 RandomForest와 ExtraTrees는 Hit@1, MRR값은 증가하고 Hit@3, Hit@5 값은 감소하는 유사한 결과를 보였으나 HistGradientBoosting은 모든 항목의 값이 증가했음을 확인하였다.			
결론적으로 최종 재학습 시나리오에서 HistGradientBoosting이 4개 지표에서 모두 가장 좋은 값을 보인다. 최종 재학습 시나리오뿐만 아니라 다른 연도 조건에서도 HistGradientBoosting이 전반적으로 좋은 지표값을 가지는 것을 확인할 수 있었다. 최신성 검증 조건에서는 RandomForest가 일부 지표에서 더 좋은 값을 보이긴 했으나, HistGradientBoosting 또한 경쟁력이 있다고 생각된다.			
만일 실제로 최종 모델 1개만 고른다면 HistGradientBoosting이 주 평가 측인 2025 test에서 가장 강하고, 연도 통합 후에도 전체 성능이 가장 균형 있게 좋으므로 가장 무난하고, 또 가장 좋은 선택이라고 생각된다. 그러나 만일 2026년의 최신성을 더 우선시되는 지표로 삼을 경우 RandomForest도 매력적인 후보가 될 수 있다.			
2. 규칙 기반 프리셋			

가) 프리셋 설정			
프리셋이란 실무자가 상황에 따라 선택하게 되는 추천 기준으로 균형형, 안정성 중심, 사회적 가치 중심, 위험 회피 중심 4가지를 기준으로 두었다. 각 프리셋의 사용 기준과 중요하게 보는 기준은 다음과 같다.			
프리셋	사용 기준	중요하게 보는 기준	요약
균형형	특별히 한쪽 기준에 치우치지 않고 전체적으로 업체를 비교할 때	낙찰 이력, 제조 여부, 사회적 가치, 제재 위험	가장 기본으로 사용할 수 있는 표준 추천 기준
안정성 중심	납품 실패 위험을 줄이고, 과거 수행 경험이 검증된 업체를 우선 보고 싶을 때	낙찰건수, 최근낙찰건수, 낙찰금액합계, 제조업체	수행 경험과 최근 활동성이 높은 업체를 우선 추천하는 기준
사회적 가치 중심	사회적 책임 구매 목표 달성을 우선하고 싶을 때	창업기업, 사회적기업, 사회적협동조합, 장애인표준사업장, 생산품목매칭	사회적 책임 지표가 있는 업체를 더 높게 평가하는 기준
위험 회피 중심	부정당제재 등 위험 요소가 있는 업체를 강하게 피하고 싶을 때	부정당제재, 현재 제재여부, 낙찰 이력, 제조 여부	제재 이력과 현재 위험 신호를 강하게 감점하는 기준
나) feature 설정 및 수정 프리셋 설정			
본 분석에서는 환경시설 관급자재 공급업체 선정을 위해 프리셋별로 후보업체를 평가할 항목(feature)을 설정하였다. feature는 AI 모델과 규칙기반 점수 계산에서 업체를 판단하고 점수를 부여할 기준이 되는 변수이며 설정한 주요 feature들의 종류와 점수는 다음과 같으며 괄호 안 점수는 균형형, 안정성 중심, 사회적 가치 중심, 위험 회피 중심, 수정 프리셋 순서이다.			

feature	점수	이유
대표물품	가점(5, 5, 2, 3, 5)	해당 물품 전문성 신호
제조업체	가점 (5, 10, 3, 7, 8)	직접 제조 가능성, 공급 안정성
낙찰건수	가점 (20, 30, 5, 25, 18)	공공조달 수행 경험
최근낙찰건수	가점 (10, 20, 5, 15, 12)	최근 활동성
낙찰금액합계	가점 (10, 20, 5, 15, 5)	수행 규모 경험, 단 보조 지표
창업기업	가점 (8, 3, 15, 5, 8)	정책 지원 대상 기업
사회적기업	가점 (10, 5, 20, 8, 10)	사회적 가치 실현 기업
사회적협동조합	가점 (7, 3, 15, 5, 7)	공동체·사회적 목적 조직
장애인표준사업장	가점 (10, 5, 20, 8, 10)	장애인 고용 관련 사회적 가치
공공구매인증서	가점 (5, 2, 5, 4, 7)	공공구매 정책 인증
자활용사춘복지공장	가점 (5, 2, 5, 5, 5)	보훈·복지 관련 사회적 책임 지표
생산물목매칭	가점 (5, 2, 10, 5, 5)	발주 물품과 생산품목 일치
부정당제재	감점 (100, 120, 100, 200, 40)	공공조달 위험 신호
현재 제재여부	감점 (60, 80, 50, 150, 120)	현재 계약 위험이 큰 상태
수정 프리셋에서는 대형 업체 쏠림을 줄이기 위해 낙찰 금액 합계를 낮추었고, 실제 납품 가능성과 최근 활동성을 반영하기 위해 제조업체, 최근낙찰건수 가중치를 높였다. 또한, 과거에 제재를 당한 이력이 있을 경우 감점을 하되, 과도한 배제를 피하였으며 현재 제재 중인 업체에 실제 구매 위험을 고려해 감점 점수를 더 가중하였다.		
또한, 수정 프리셋에서는 기존 feature 외에 최근 낙찰일 경과일수, 인증 유효 여부, 정책구매 목표기여도, 대체 가능성, 권역 근접성 feature를 추가하였다. feature별 점수는 다음과 같다.		
추가 feature	의미	점수
최근 낙찰일 경과일수	최근 낙찰일이 가까울수록 공급 활동성이 높다고 봄	10
인증유효여부 숫자	인증이 현재 유효한지 확인	3
정책구매 목표 기여도 단순합	정책구매 관련 인증/지표를 몇 개 보유했는지 합산	3
대체가능성 정책인증업체수	같은 물품에 정책인증 업체가 얼마나 있는지	2
부울경권역여부	부산·울산·경남 권역 업체 여부	3
추가 feature는 실제 데이터 품질과 해석 가능성을 기준으로 반영 여부를 구분하였다.		
이 외에도 견적/가격 경쟁력 feature를 반영하려고 하였으나, 낙찰률이 너무 높을 경우 경쟁력이 낮을 수 있		

고, 너무 낮을 때 무리한 저가 낙찰일 확률도 고려하여 단순히 높고 낮음에 따라 우수함을 판단하기에 부적절한 면이 존재했다. 또한, 적정 범위 판단 기준이 필요하여 점수 반영을 보류하였다.
IV. 인사이트 및 해결책
본 분석을 통해 단순히 사회적 책임 구매 목표를 달성하기 위해 장애인 표준사업장, 사회적기업, 창업 기업 등과 같이 단순히 사회적 지표만으로 결론을 내리는 것은 무리가 있다고 판단하였다. 실무자가 구매 의사를 결정하는 데 해당 업체가 대상 물품을 공급할 수 있는지에 대한 여부를 파악하여야 하는 것은 물론, 최근에도 시장에 참가한 이력이 있는지, 과거 또는 현재 제재를 받은 이력이 있거나 위험 가능성이 없는지, 정책구매 지표에 얼마나 이바지할 수 있는지 등과 같은 다양한 지표를 고려해야 원활한 조달이 가능하다는 것을 파악했다.
따라서 본 연구에서는 후보 업체를 단순히 목록으로 제시하는 것이 아니라, 물품별로 업체를 정리한 뒤 AI를 기반으로 한 랭킹 모델과 규칙 기반 프리셋 점수를 함께 적용하였다. AI 모델은 물품별로 과거 낙찰 패턴을 바탕으로 업체를 선정하였고, 규칙기반 프리셋은 사회적 책임, 공급 안정성, 위험 회피 등과 같이 실무자가 이해할 수 있는 기준으로 추천 결과를 설명하는 역할을 한다. 특히 기존 프리셋에서 수정을 거친 ‘수정 프리셋’에서는 기존의 실적 중심 점수 반영을 보완하기 위해 feature를 추가하였으며, 낙찰금액합계의 영향을 완화하였다. 또한, 제조업체 여부와 최근 낙찰 활동성, 현재 제재 여부에 점수를 더 높여 반영도를 높였다. 또한 인증 유효성과 정책구매 목표기여도, 대체가능성, 권역 근접성 등을 보조 feature로 추가하여 실제 구매 현장에서 활용할 수 있는 판단 기준을 보완하였다.
최종 결과는 대시보드에서 물품별 AI 추천 Top5와 규칙 기반 점수를 기반으로 한 Top5를 함께 확인할 수 있도록 구성하였다. 이를 통해 담당자는 AI가 추천한 후보 중 어떤 업체가 사회적 목표에 기여할 수 있는지, 제재 위험성이 높은지 등, 규칙 기반 점수를 보조 도구로 활용하여 업체 선정 과정에서 원활한 비교가 가능하다. AI 점수와 규칙 기반 점수가 모두 높을 경우, 해당 업체는 우선적으로 검토 후보로 볼 수 있다. 반면 AI 점수와 규칙 기반 점수 간에 차이가 있을 경우 검토가 필요하다. AI 점수가 높고 규칙 기반 점수가 낮을 경우, 사회적 책임 기여도나 위험 요인 측면에서 추가 검토가 필요하다. 반대로 AI 점수가 낮고 규칙 기반 점수가 높을 경우 정책구매 측면에서는 적절하나 실제 낙찰 가능성이나 공급 실적이 부족할 수 있으므로 이에 대한 확인이 필요하다. 또한, 공공조달 원천 데이터는 기간별 데이터량이 크고 API 호출 및 전처리 비용이 높기 때문에, 발주 요청 시점마다 전체 데이터를 실시간 수집·분석하는 방식은 적합하지 않다. 따라서 본 시스템은 원천 데이터를 주기적으로 수집·정제하고, 후보업체 목록과 AI 예측 결과를 사전에 생성한 뒤, 발주 담당자가 대시보드에서 품목·금액 조건에 따라 빠르게 비교할 수 있는 준실시간 의사결정 지원 방식으로 설계하였다.
다만 본 분석에는 몇 가지 아쉬운 부분이 있다. 우선 데이터 전처리를 진행할 때 가장 안정적인 결합 키는 사업자번호였지만, 사회적 기업이나 자활용사춘 복지공장처럼 사업자번호가 없는 자료는 식별자 매칭의 제약으로 인해 업체명 정규화 매칭에 의존할 수밖에 없었다. 우선순위 평가 방식에서도 분석 시 Hit@n, MRR을 지표로 사용했으나, 이것만으로 변동성이 크고 현장에서 변동되는 일이 큰 실제 현장에서의 우선순위를 맞출 수는 없다는 아쉬움이 있었다. 또한 샘플은 전체 시장의 모든 비낙찰 업체가 아니라 공급 가능 후보군 안에서 샘플링을 진행했고, 따라서 모델은 절대적 낙찰확률이라기보다는 후보 내부에서의 우선순위를 잘 매기는 모델에 가깝기 때문에 실제로 무작위적인 비낙찰 업체들에 대해서는 분석 결과가 어떻게 나올지 알 수 없다는 아쉬움이 있었다. 또한 현재 제출본은 대표 환경기설 관급자재 10개 품목을 중심으로 구조가 설계됐기 때문에, 전체 품목군으로 일반화하려면 추가 검증이 필요하다.
V. 정책 활용 및 기대효과
1. 행정 효율화 해당 분석은 공공조달 실무에서 관급자재 후보 업체를 선별하고 우선순위를 정하는 의사결정 보조 체계로 활용될 가능성이 있다고 생각된다. 과거 낙찰 실적에 창업기업, 장애인표준사업장, 사회적 기업, 공공구매인증서, 자활용사춘 복지공장 등 다양한 정책성 항목과 부정당제재 이력을 함께 반영함으로써 후보 업체 들을 보다 체계적으로 선별할 수 있다. 또한, 가중치 프리셋을 조정하는 방식으로 기관별 선호에 따른 기준을 유연하게 적용할 수 있으므로 여러 실무 환경에 따른 맞춤형 활용이 가능하다. 특히 본 분석은 구매 의사결정 이전 단계에서 사회적 책임 구매 목표 달성 여부가 높은 업체를 미리 제시한

다는 점에서 정책적 활용성이 높다. 담당자는 물품별 후보업체 중 사회적 가치 지표를 보유한 업체, 제재 위험이 낮은 업체, 공급 가능성이 높은 업체 등 이를 통해 구매 목표 달성과 안정적 조달 사이의 균형을 고려한 의사결정이 가능하다. 또한, 부정당제재 여부, 현재 제재 상태, 인증 유효성 등 위험 관리 지표를 함께 반영하여 단순히 사회적 가치가 높은 업체를 선별하는 것에만 그치지 않고, 실제 계약 이행 단계에서 발생할 수 있는 리스크를 최대한 줄이고 사전에 확인하는 것이 가능하다. 이를 통해 책임감과 신뢰성을 높일 수 있으며, 사회적 책임 구매 실적 관리와 안정적인 공급망 관리라는 두 가지 목적을 실현할 수 있다.

기존에는 담당자가 물품별 후보업체를 직접 찾고, 인증 여부와 제재 여부 등의 내용을 직접 확인해야 했던 만큼 시간이 오래 걸린다는 단점이 존재했다. 해당 분석은 대시보드를 통해 추천 업체와 사회적 책임 지표, 위험 요인과 같이 기존에 하나씩 찾아봐야 하는 내용들을 한눈에 확인이 가능하므로 반복적인 자료 확인 업무를 자동화할 수 있게 된다. 또한, 기대효과 측면에서는 후보업체 탐색과 검토에 소요되는 시간을 줄이고, 조달 과정의 효율성과 투명성을 높일 수 있다고 예상된다. 기존의 규칙 기반 방식에 AI 기반 랭킹 모델을 더해 보다 효율적으로 적합한 업체를 제시할 수 있으며, 이를 통해 해당 직무 담당자의 부담을 줄이고 사무와 실무를 동시에 만족시키는 방향으로 활용할 수 있을 것이라 기대한다. 더불어 동일한, 또는 유사한 구조를 다른 품목이나 다른 공공기관 업무로 확장하면 또 다른 데이터 기반 의사결정 체계 구축에도 응용할 수 있다는 가능성이 존재한다.

2. 정밀 B/C 분석

비용 측면에서는 데이터 수집 API 유지, 모델 갱신, 대시보드 운영, 담당자 교육 비용 등이 발생할 수 있을 것으로 생각된다. 그러나 후보 업체 탐색 시간 단축과 사회적 책임 구매 실적 관리 효율화, 제재 업체 사전 확인에 따른 리스크 감소, 업무 자동화 등을 고려할 경우 편익 측면에서는 인건비 절감 효과를 기대할 수 있을 것이라고 생각된다. 향후 실제 도입 시에는 건당 후보업체 검토 소요 시간, 연간 구매 건수, 담당자 평균 인건비, 제재 업체 사전 차단 건수 등을 기준으로 정량적인 B/C 분석을 수행할 수 있다.

3. 리스크 관리

본 모델은 최종 의사결정에 있어 자동으로 대체하는 것이 아니라, 담당자의 1차 검토 지원 도구로 사용해야 한다. AI 추천 결과만을 반영하여 업체를 결정하게 될 경우, 특정 업체에 대한 편향이나 설명 가능성 문제가 발생할 수 있으므로 규칙기반 점수와 인증 여부, 제재 여부와 원천 데이터 확인 절차를 거쳐야 한다. 또한, 일부 데이터의 경우 사업자 번호가 없어 오매칭 가능성이 있으므로, 최종 계약 전에는 원천 데이터와 공식 등록 정보를 재확인하는 절차가 필요하다. 민원이 발생할 경우 담당자가 의사 결정에 있어 중요하다고 생각한 프리셋이 무엇인지에 대해 기록하고, feature별 반영된 점수를 검토 후 AI 지표는 1차 검토 지원 도구로만 사용되었을 뿐 최종 결정은 담당자가 수행했다는 운영 원칙을 명시하도록 한다.

부정당제재업체 정보는 추천 업체가 단순히 낙찰 경험이 있거나 공급물품 등록이 되어 있다는 것만으로 좋은 후보라고 보기 어렵기 때문에 과거 제재 이력이 있는 업체는 계약 안정성이나 신뢰성 측면에서 위험 요인이 될 수 있으므로, 추천 점수에 반영하여 법적·행정적 리스크를 사전에 줄이는 요소로 사용한다. 다만 현재 수집 파일 기준으로는 일부 확인 또는 보완 대상이며, 전체 기간을 완전히 수집한 경우에는 2020~2021년 낙찰·공급 물품 데이터와 같은 기준으로 매칭하면 된다.